



Super-Resolución



El método Super-Resolution Convolutional Neural Network (SRCNN) propuesto en Dong et al. "Image super-resolution using deep convolutional networks". Superando ampliamente al desempeño de métodos como el interpolador Bicúbico.



Métodos de DLSS (Deep Learning Super Sampling) de Nvidia que permiten ganar performance procesando gráficos a baja resolución para luego escalarlos utilizando modelos, se puede observar que mantiene calidad visual a mucho mayor FPS.

En la tarea de super-resolución de imágenes individuales, una red recibe como entrada una imagen de baja resolución y genera como salida una versión de mayor resolución de la misma (**¡una imagen más grande!**).

Este es en general, un problema sub-especificado, es decir, hay muchas posibles imágenes de alta resolución que podrían corresponder a la misma imagen de baja resolución. Sin embargo, al entrenar en conjuntos de datos de imágenes de alta y baja resolución correspondientes, una red neuronal puede aprender patrones sobre el mundo visual que le permiten predecir una salida plausible de alta resolución para cualquier entrada de baja resolución.

De forma similar a la segmentación semántica, se puede usar una red totalmente convolucional (*fully-convolutional network*) para construir un modelo de super-resolución de imágenes individuales.

La entrada del modelo es una imagen de baja resolución de forma $3 \times H \times W$; la imagen pasa por una serie de capas de convolución y capas de aumento de escala (usando interpolación de vecino más cercano, bilineal, o convolución traspuesta) y finalmente produce una salida de alta resolución de la forma $3 \times fH \times fW$, donde f es el factor de super-resolución (en general tenemos que $f=2$, $f=3$ o $f=4$). Durante el entrenamiento, la salida de la red se compara con la salida real usando una función de pérdida L2, L1 o alguna otra.

El objetivo de este proyecto es implementar y entrenar una red convolucional para super-resolución de imágenes individuales. Se espera que entrenen modelos para al menos dos factores de super-resolución ($f=2$ y otro a elección).

Para esto deberán diseñar y proponer una arquitectura inspirándose en artículos científicos académicos. Deberán mostrar resultados de entrenamiento y validación utilizando métricas particularmente relevantes para este tipo de tarea específica. Les recomendamos seguir el siguiente trabajo científico como guía metodológica:

SRCNN: Dong et al, "Image super-resolution using deep convolutional networks", TPAMI 2015. [[arXiv](#)]

Artículos recomendados

A continuación listamos artículos fundacionales de la técnica de super-resolución, cada uno propone una nueva metodología y están en orden ascendente de complejidad:

- **SRCNN**: Dong et al, "Image super-resolution using deep convolutional networks", TPAMI 2015. [[arXiv](#)]
- **FSRCNN**: Dong et al, "Accelerating the super-resolution convolutional neural network", ECCV 2016. [[arXiv](#)]

- **SRGAN**: Ledig et al, "Photo-Realistic Single Image Super-Resolution using a Generative Adversarial Network", CVPR 2017. [[arXiv](#)]

Pueden buscar otras soluciones en las cuales inspirarse. Se recomienda comenzar copiando una de las arquitecturas más sencillas y luego probar otras arquitecturas.

Conjunto de datos

Pueden entrenar un modelo en cualquier conjunto de datos de imágenes que elijan; los conjuntos de datos de ImageNet o COCO son opciones bastante populares. La super-resolución generalmente no requiere conjuntos de datos muy grandes para el entrenamiento.

Por ejemplo, **FSRCNN** se entrena en un conjunto de datos de 100 imágenes llamado General100 (<http://mmlab.ie.cuhk.edu.hk/projects/FSRCNN.html>), que podría resultarles útil para una implementación propia. Consulten la Sección 4.1 del artículo de **FSRCNN** para obtener más detalles sobre cómo preparar el conjunto de datos de entrenamiento.

Deberán evaluar su modelo en los conjuntos de datos **Set5** y **Set14**. Durante la evaluación, la manera precisa en la que preparan las imágenes de baja y alta resolución es importante; por esta razón, deberían usar las versiones de los conjuntos de datos **Set5** y **Set14** de [este repositorio de GitHub de Jia-Bin Huang](#). Tengan en cuenta que existen versiones diferentes de los conjuntos de datos para cada factor de super-resolución.

Modelo

Deberían implementar al menos un modelo similar a **SRCNN** o **FSRCNN**; sigan los detalles en los artículos lo más cerca posible.

Se recomienda entrenar el modelo primero con el objetivo de obtener imágenes al doble de escala $f=2$, lograr convergencia del modelo en ese escenario y luego intentar factores de escala mayores como $f=4$, etc..

Como una extensión opcional, también podrían considerar usar una red generativa adversarial para super-resolución como se describe en el artículo de SRGAN. Entrenar el modelo adversarialmente contra un discriminador aprendido puede producir imágenes de mayor calidad perceptual, aunque con un PSNR o SSIM ligeramente inferior en comparación con un modelo entrenado solo con pérdidas L2 o L1.

El informe debe incluir una sección que describa la arquitectura del modelo, las funciones de pérdida de entrenamiento y cualquier otro detalle de implementación importante de tu modelo. Deberían experimentar con distintos

optimizadores, funciones de pérdidas, arquitecturas de modelo u otras variaciones que se les ocurran. Deberían mostrar los resultados de al menos **dos** variantes diferentes del modelo para cada factor de super-resolución que consideren.

Evaluación

Deberían evaluar el modelo tanto en imágenes no vistas de tu conjunto de entrenamiento como también en los conjuntos de datos Set5 y Set14. Pueden opcionalmente elegir reportar resultados adicionales en los conjuntos de datos BSD100 o Urban100.

Para este trabajo deberán trabajar con dos métricas específicas de relación señal-ruido pico (PSNR) y la similitud estructural (SSIM). **Lean con atención los artículos científicos con respecto a esto**, pueden encontrar [implementaciones de estas métricas en scikit-image](#).

Deberían comparar tu modelo con el aumento de escala usando interpolación bilineal, bicúbico y de vecinos más cercanos; pueden usar OpenCV o scikit-image para esto. El mejor modelo debería superar ambos métodos de referencia en los factores de super-resolución que consideren.

Concretamente, para un factor de super-resolución de 2 deberían alcanzar un PSNR de al menos 34 en Set5; para un factor de super-resolución de 3 deberían alcanzar un PSNR de al menos 31 en Set5; y para un factor de super-resolución de 4 deberían alcanzar un PSNR de al menos 29 en Set5.

Canales de Color

Un detalle importante de los métodos de super-resolución es el canal de color que el modelo utiliza para el entrenamiento y la evaluación. Hasta ahora en este curso, todas las imágenes se han representado en el espacio de color RGB estándar; sin embargo, existen otros espacios de color que se utilizan comúnmente para representar imágenes. Uno importante es el espacio de color YCbCr. En este espacio de color, Y es un canal de color en escala de grises (luma) y Cb y Cr son dos canales que dan el color de la imagen (croma). Podés convertir entre RGB y YCbCr usando funciones de OpenCV o scikit-image.

Para la super-resolución de imágenes individuales, una configuración común es transformar la imagen del espacio de color RGB al espacio de color YCbCr; la red neuronal recibe el canal Y de baja resolución y predice un canal Y de alta resolución, mientras que los canales Cb y Cr se amplían mediante interpolación bicúbica. La pérdida de entrenamiento compara los canales Y predicho y el real, y durante la evaluación calculamos PSNR y SSIM entre los canales Y predicho y real.

Deberían seguir esta convención en la implementación. También es posible entrenar modelos de super-resolución usando entradas y salidas en color; para

más detalles, consulten la Sección 4.5 del artículo de SRCNN. Pueden realizar experimentos adicionales con canales de color adicionales de forma opcional.

Conclusión

Para resumir, en este proyecto se espera que:

- Implementen modelos para super-resolución de imágenes individuales. Deberías entrenar modelos para al menos dos factores de super-resolución diferentes (2x, 3x o 4x). Para cada modelo deberías mostrar curvas de entrenamiento (pérdida en el conjunto de entrenamiento y PSNR en un conjunto de validación no visto a lo largo del entrenamiento). Para cada modelo deberías reportar el rendimiento en los conjuntos de datos Set5 y Set14 usando PSNR y SSIM.
- Deberían comparar tu modelo con el aumento de escala con interpolación bilineal, bicúbico y vecinos más cercanos, y tu modelo debería superar estos métodos de referencia.
- Para factores de super-resolución 2x / 3x / 4x, deberías lograr PSNR en Set5 de al menos 34 / 31 / 29.
- También deberían mostrar resultados cualitativos. Por ejemplo, podés mostrar la imagen de baja resolución, la imagen de alta resolución real y la imagen de alta resolución predicha para cada método que consideres (y los métodos bilineal / bicúbico / vecinos más cercanos) para varios ejemplos de un conjunto de validación no visto, así como para cada imagen en Set5.