

Super resolución eficiente de imagen única: ¿alcanza un modelo pequeño? FSRCNN residual y ensamble por simetrías frente a EDSR

Axel Fritz Santiago Bunge

Departamento de Ingeniería, Universidad de San Andrés
afritz@udesa.edu.ar sbunge@udesa.edu.ar

Resumen—Se aborda el problema de super resolución de imagen única mediante modelos convolucionales de la familia SRCNN y FSRCNN, evaluados sobre los conjuntos Set5, Set14, BSD100 y Urban100 en factores de escala 2, 3 y 4. Como aporte propio se introduce una variante de FSRCNN que predice el residuo sobre la interpolación bicúbica y se complementa con un ensamble por simetrías en la etapa de inferencia. Esta combinación supera a la versión base de FSRCNN en las tres escalas y alcanza una calidad comparable a la de EDSR, una red cerca de setenta veces más grande, usando una fracción de los parámetros. El trabajo también analiza el efecto del tamaño del conjunto de entrenamiento sobre los modelos de mayor capacidad y el compromiso entre distorsión y percepción al incorporar pérdidas perceptuales y adversarias.

I. INTRODUCCIÓN

La super resolución de imagen única consiste en reconstruir una versión de alta resolución a partir de una imagen de baja resolución. Es un problema mal condicionado, ya que al reducir el tamaño de una imagen se pierde información que luego debe estimarse. Muchas imágenes de alta resolución distintas pueden dar lugar a la misma imagen reducida, de modo que no existe una única solución correcta y el modelo debe inferir el detalle ausente. Los métodos clásicos de interpolación, como vecino más cercano, bilineal y bicúbico, ofrecen una solución rápida pero producen bordes difusos y texturas pobres.

El trabajo de Dong et al. mostró que una red convolucional sencilla, SRCNN, supera a la interpolación bicúbica, y su versión acelerada, FSRCNN, mejora la velocidad operando en el espacio de baja resolución. Modelos posteriores como EDSR incrementan fuertemente la capacidad y la calidad a costa de muchos más parámetros y mayor cómputo. La super resolución tiene aplicaciones concretas en restauración de fotografías, imágenes satelitales y médicas, y en el escalado de video en tiempo real, donde el costo computacional es tan relevante como la calidad.

En este informe se implementa una progresión de arquitecturas, desde SRCNN hasta EDSR, y se propone una mejora propia sobre FSRCNN. El objetivo no es únicamente maximizar la calidad, sino estudiar la relación entre calidad, tamaño del modelo y costo de inferencia. La pregunta que guía el análisis es si un modelo pequeño, bien diseñado y bien explotado, puede competir con uno mucho mayor. Las contribuciones del trabajo son tres. Primero, una variante residual de FSRCNN que mejora la calidad sin agregar parámetros.

Segundo, el uso de un ensamble por simetrías en inferencia que aporta una ganancia adicional sin reentrenar. Tercero, un análisis del efecto del tamaño del conjunto de entrenamiento sobre los modelos grandes, que muestra que la capacidad adicional de EDSR solo rinde con suficientes datos.

II. MÉTODO

II-A. Convención de evaluación

Todas las métricas se calculan sobre el canal de luminancia Y en el espacio YCbCr, siguiendo la convención de la literatura del área. Se utiliza la conversión a YCbCr al estilo de MATLAB, con rango acotado entre 16 y 235, y se descarta un borde de tamaño igual al factor de escala antes de medir, ya que esos píxeles son artefactos del agrandado. La calidad se reporta con PSNR y con el índice de similitud estructural SSIM. Estas decisiones no son menores: medir sobre los tres canales de color o sin descartar el borde produce valores de PSNR distintos que no se pueden comparar con los publicados. Para garantizar que la medición es correcta se valida que el PSNR de la interpolación bicúbica coincide con los valores publicados, lo que actúa como control previo a cualquier comparación entre modelos.

II-B. Arquitecturas

Se entrenaron cuatro arquitecturas de capacidad creciente:

- **SRCNN**: tres convoluciones aplicadas sobre la imagen previamente agrandada por interpolación bicúbica. Opera en alta resolución, por lo que resulta más lenta y costosa.
- **FSRCNN**: trabaja directamente en baja resolución y agranda al final mediante una capa de deconvolución. Su estructura combina una etapa de reducción de dimensión, varias capas de mapeo no lineal y una etapa de expansión, lo que la vuelve rápida y liviana, con cerca de trece mil parámetros. Constituye el modelo base.
- **FSRCNN residual**: variante propuesta en este trabajo, descrita más abajo.
- **EDSR**: red profunda formada por bloques residuales sin normalización por lotes y un agrandado final por reordenamiento de píxeles. Posee cerca de un millón de parámetros, dos órdenes de magnitud por encima del modelo base.

II-C. Mejora propia

La mejora propuesta tiene dos componentes. El primero es una conexión residual sobre la interpolación bicúbica. En lugar de que la red reconstruya la imagen completa desde cero, predice solamente el residuo que debe sumarse a la versión bicúbica:

$$\hat{y} = \text{bicúbica}(x) + f_{\theta}(x), \quad (1)$$

donde x es la imagen de baja resolución y f_{θ} la red. La interpolación bicúbica ya aporta las zonas suaves y la estructura general de la imagen, que son la parte fácil del problema. Al predecir solo el residuo, la red concentra su capacidad en los bordes y las texturas finas, que es donde la interpolación falla. Esto facilita el aprendizaje, acelera la convergencia y mejora la calidad sin agregar parámetros. La idea sigue el aprendizaje residual introducido en VDSR.

El segundo componente es un ensamble por simetrías en inferencia, conocido como self-ensemble. La imagen se procesa en sus ocho orientaciones, que surgen de combinar cuatro rotaciones con un espejo horizontal. Cada salida se devuelve a su orientación original aplicando la transformación inversa y luego se promedian las ocho reconstrucciones. Como los errores que comete la red en cada orientación son distintos, el promedio tiende a cancelarlos y mejora el PSNR sin necesidad de reentrenar. El costo es multiplicar por ocho el número de evaluaciones, lo que se traduce en mayor tiempo de inferencia.

II-D. Funciones de pérdida

Para el modelo base se compararon tres funciones de pérdida: el error absoluto medio L1, el error cuadrático medio L2 y la pérdida de Charbonnier, que es una aproximación suave de L1 más robusta a valores atípicos. Además, sobre EDSR en escala 4 se entrenaron dos variantes orientadas a la percepción. La primera usa una pérdida perceptual que compara características intermedias de una red VGG19 pre-entrenada, en lugar de comparar píxeles directamente. La segunda agrega un esquema adversario al estilo de SRGAN, en el que un discriminador aprende a distinguir imágenes reales de generadas y el generador aprende a engañarlo. Ambas buscan estudiar el compromiso entre distorsión y percepción.

II-E. Detalles de entrenamiento

Los modelos se entrenaron con el optimizador Adam, tasa de aprendizaje inicial de 10^{-3} , parches de baja resolución de 24 por 24 píxeles y ocho mil parches por época, extraídos con aumentos de datos por espejos y rotaciones. El modelo base se entrenó durante 150 épocas con lotes de 64 muestras, mientras que EDSR usó lotes de 16 por su mayor tamaño. La variante de EDSR entrenada con DIV2K usó una tasa de aprendizaje de 10^{-4} y 300 épocas. El entrenamiento se realizó en una GPU T4 sobre la plataforma Kaggle.

III. CONJUNTOS DE DATOS

El entrenamiento principal se realizó con **T91**, conjunto de 91 imágenes que es el estándar de los trabajos originales de SRCNN y FSRCNN. De cada imagen se extraen parches, de

modo que el número efectivo de ejemplos de entrenamiento es mucho mayor que la cantidad de imágenes. Los pares de baja y alta resolución se generan reduciendo la imagen original con interpolación bicúbica al estilo de MATLAB, de modo que la degradación coincide con la usada en la evaluación y se evita un desajuste entre entrenamiento y prueba.

Para estudiar el efecto del tamaño del conjunto sobre los modelos grandes se reentrenó EDSR con un subconjunto de cerca de doscientas imágenes de **DIV2K**, que contiene imágenes de alta resolución mucho mayores y más variadas que las de T91.

La evaluación se hizo sobre cuatro conjuntos de prueba estándar, Set5, Set14, BSD100 y Urban100, en las versiones de pares de baja y alta resolución del repositorio SelfExSR. Set5 y Set14 son conjuntos pequeños y clásicos, BSD100 reúne cien imágenes naturales variadas y Urban100, compuesto por escenas urbanas con muchas líneas y estructuras repetitivas, es el más exigente. Las referencias a los conjuntos se incluyen al final.

IV. RESULTADOS

La Tabla I resume el PSNR sobre Set5 para los baselines y los modelos principales en las tres escalas. Todos los modelos entrenados superan a los baselines de interpolación y a los valores objetivo de la consigna, fijados en 34, 31 y 29 dB para escala 2, 3 y 4. La variante residual mejora de manera consistente al modelo base, y el agregado del ensamble por simetrías aporta una ganancia adicional que lleva al modelo pequeño por encima de EDSR en las tres escalas.

Cuadro I
PSNR (dB) SOBRE SET5, CANAL Y. SE INDICA ENSAMBLE POR SIMETRÍAS.

Método	x2	x3	x4
Bicúbica (baseline)	33.68	30.41	28.43
SRCNN	36.37	—	30.27
FSRCNN	36.11	32.19	30.09
FSRCNN residual	36.74	32.94	30.66
FSRCNN residual + SE	37.05	33.13	30.90
EDSR (entrenado con T91)	36.57	32.87	30.32
EDSR (entrenado con DIV2K)	37.00	33.01	30.71
Objetivo de la consigna	34	31	29

La Tabla II extiende la comparación al resto de los conjuntos de prueba en escala 4. La ventaja del modelo residual con ensamble por simetrías se mantiene en los cuatro conjuntos, incluido Urban100, que es el más difícil. Esto indica que la mejora no depende de un conjunto particular sino que generaliza.

Observando la Tabla II en detalle, la diferencia entre el modelo pequeño y EDSR se acentúa en Urban100, el conjunto con más estructuras finas y repetitivas. Allí el modelo residual con ensamble por simetrías alcanza 24.66 dB frente a 24.55 dB de EDSR entrenado con DIV2K, lo que refuerza que la ventaja no proviene de un conjunto particularmente favorable. En Set14 y BSD100 el comportamiento es análogo, con mejoras de entre una y dos décimas de decibel sobre EDSR.

Cuadro II
PSNR (dB) / SSIM SOBRE LOS CUATRO CONJUNTOS DE PRUEBA, FACTOR DE ESCALA 4, CANAL Y.

Método	Set5	Set14	BSD100	Urban100
Bicúbica (baseline)	28.43 / 0.8232	26.09 / 0.7217	25.96 / 0.6857	23.14 / 0.6736
FSRCNN	30.09 / 0.8668	27.28 / 0.7651	26.74 / 0.7265	24.14 / 0.7257
FSRCNN residual	30.66 / 0.8811	27.69 / 0.7753	26.96 / 0.7339	24.56 / 0.7439
FSRCNN residual + SE	30.90 / 0.8850	27.81 / 0.7788	27.05 / 0.7367	24.66 / 0.7477
EDSR (T91)	30.32 / 0.8772	27.39 / 0.7714	26.79 / 0.7315	24.39 / 0.7389
EDSR (DIV2K)	30.71 / 0.8810	27.67 / 0.7756	26.95 / 0.7355	24.55 / 0.7457
EDSR adversario (SRGAN)	29.06 / 0.8283	26.57 / 0.7303	26.13 / 0.6950	23.82 / 0.7017

La Tabla III reúne la cantidad de parámetros de cada arquitectura por factor de escala. El salto entre el modelo base y EDSR es de casi dos órdenes de magnitud, lo que vuelve más notable que el modelo pequeño alcance una calidad similar.

Cuadro III
CANTIDAD DE PARÁMETROS POR ARQUITECTURA Y FACTOR DE ESCALA.

Arquitectura	x2	x3	x4
FSRCNN y FSRCNN residual	12.809	12.809	12.809
EDSR	776.705	961.345	924.417

La Tabla IV muestra la ablación de la función de pérdida sobre FSRCNN en escala 2. La pérdida L2 obtiene un PSNR levemente superior, lo que es esperable dado que optimiza directamente el error cuadrático sobre el que se define el PSNR, mientras que L1 y Charbonnier dan resultados muy cercanos entre sí.

Cuadro IV
EFECTO DE LA FUNCIÓN DE PÉRDIDA (FSRCNN, SET5, X2).

Pérdida	PSNR (dB)
L1	36.11
L2	36.41
Charbonnier	36.21

La Tabla V compara calidad y costo. El modelo residual tiene cerca de trece mil parámetros, frente a casi un millón de EDSR. Sin ensamble por simetrías es el más veloz por un margen amplio, con una calidad apenas inferior. Con el ensamble alcanza la mejor calidad, a costa de un tiempo de inferencia mayor por las ocho pasadas. La ventaja en cantidad de parámetros se mantiene en todos los casos y se traduce en menor uso de memoria y almacenamiento.

Cuadro V
CALIDAD FRENTE A COSTO (SET5, X2). LATENCIA MEDIDA EN UNA GPU LOCAL.

Modelo	Parámetros	PSNR	ms/img
FSRCNN residual	12.809	36.74	0.9
FSRCNN residual + SE	12.809	37.05	21.8
EDSR (T91)	776.705	36.57	18.2
EDSR (DIV2K)	776.705	37.00	18.0

Las curvas de convergencia de la Figura 1 muestran que la variante residual no solo alcanza un PSNR mayor sino que

estabiliza antes que el resto. Las Figuras 2 y 3 presentan comparaciones visuales en escala 2 y 4, donde se aprecia la recuperación de bordes respecto de la interpolación bicúbica. La Figura 4 ubica a cada modelo en el plano calidad contra latencia, donde se observa que el modelo pequeño domina la región de bajo costo.




Figura 1. Curvas de convergencia (PSNR de validación sobre Set5) para el factor 4.



Figura 2. Resultado cualitativo en Set5, escala 2.




Figura 3. Resultado cualitativo en Set5, escala 4. De izquierda a derecha, baja resolución, bicúbica, modelos y referencia de alta resolución.

V. DISCUSIÓN

Los resultados permiten varias lecturas. En primer lugar, la mejora propia cumple su objetivo. La conexión residual sobre




Figura 4. Calidad frente a costo computacional por modelo en escala 4.

la interpolación bicúbica eleva el PSNR en las tres escalas sin sumar parámetros, y el ensamble por simetrías agrega una mejora gratuita en términos de entrenamiento. La combinación lleva al modelo base de 36.11 a 37.05 dB en escala 2, una ganancia cercana a un decibel, y la ventaja se sostiene en los cuatro conjuntos de prueba.

En segundo lugar, el caso de EDSR ilustra que la capacidad sola no basta. Entrenado con las mismas 91 imágenes que el modelo pequeño, EDSR obtiene un PSNR menor, ya que su mayor cantidad de parámetros no se aprovecha con tan pocos datos y tiende a desaprovechar su capacidad. Solo al reentrenarlo con DIV2K logra superar a la versión básica del modelo pequeño, aunque sin alcanzar a la variante con ensamble por simetrías. Esto sugiere que la elección entre un modelo grande y uno pequeño no es independiente del presupuesto de datos disponible.

La Figura 5 ayuda a entender este comportamiento. Sobre T91, la curva de validación de EDSR es marcadamente más ruidosa y oscila de una época a otra, y su mejor valor no supera al del modelo residual pese a contar con sesenta veces más parámetros. La red grande tampoco logra una pérdida de entrenamiento menor que la del modelo residual, de modo que su capacidad adicional no se traduce ni en mejor ajuste ni en mejor generalización cuando los datos son escasos. La misma figura permite comparar FSRCNN y su variante residual bajo condiciones idénticas de datos, pérdida y configuración: el modelo residual mantiene una pérdida de entrenamiento más baja y un PSNR de validación más alto durante todo el entrenamiento. Esto respalda que aprender el residuo entre la imagen de alta resolución y la interpolación bicúbica es una tarea de optimización más sencilla que reconstruir la imagen completa desde cero.

En tercer lugar, el análisis de costo muestra un compromiso claro. El modelo pequeño sin ensamble es la mejor opción cuando interesa la velocidad, con una calidad apenas inferior. Con ensamble por simetrías gana en calidad pero se vuelve más lento, dado que requiere ocho evaluaciones. Aun así, mantiene una ventaja sólida en cantidad de parámetros frente




Figura 5. Curvas de entrenamiento (pérdida L1, izquierda) y validación (PSNR sobre Set5, derecha) en escala 2, para los tres modelos entrenados en condiciones idénticas sobre T91. El modelo residual domina la validación de forma estable, mientras que EDSR resulta inestable y FSRCNN queda por debajo.

a EDSR.

Por último, las variantes perceptual y adversaria confirman el compromiso entre distorsión y percepción que muestra la Figura 6. Estos modelos producen imágenes más nítidas pese a un PSNR menor, lo que evidencia que el PSNR no captura por completo la calidad percibida y que una mejora en la métrica no siempre equivale a una mejora visual.




Figura 6. Compromiso entre distorsión y percepción en escala 4. La variante adversaria genera texturas más nítidas a pesar de un PSNR inferior.

V-A. Trabajo a futuro

Quedan abiertas varias líneas. Entrenar todos los modelos con un conjunto grande permitiría una comparación pareja de arquitecturas, despejando el efecto de los datos. También sería de interés aplicar el ensamble por simetrías a EDSR, explorar redes más profundas dentro de la familia FSRCNN y evaluar con métricas perceptuales como LPIPS, que se correlacionan mejor con la percepción humana que el PSNR.

CONCLUSIÓN

Se mostró que una red pequeña, FSRCNN con conexión residual y ensamble por simetrías, compite con una red mucho mayor en super resolución de imagen única, superando los objetivos de la consigna en las tres escalas y en los cuatro conjuntos de prueba con una fracción de los parámetros. El estudio del tamaño del conjunto de entrenamiento y del compromiso entre calidad y costo aporta una mirada útil para decidir qué modelo conviene según los recursos de datos y de cómputo disponibles.

REFERENCIAS

- [1] C. Dong, C. C. Loy, K. He y X. Tang, "Image Super-Resolution Using Deep Convolutional Networks," IEEE TPAMI, 2016.
- [2] C. Dong, C. C. Loy y X. Tang, "Accelerating the Super-Resolution Convolutional Neural Network," ECCV, 2016.
- [3] J. Kim, J. K. Lee y K. M. Lee, "Accurate Image Super-Resolution Using Very Deep Convolutional Networks," CVPR, 2016.
- [4] B. Lim, S. Son, H. Kim, S. Nah y K. M. Lee, "Enhanced Deep Residual Networks for Single Image Super-Resolution," CVPR Workshops, 2017.
- [5] C. Ledig et al., "Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network," CVPR, 2017.
- [6] J.-B. Huang, A. Singh y N. Ahuja, "Single Image Super-Resolution from Transformed Self-Exemplars," CVPR, 2015. Conjuntos Set5, Set14, BSD100 y Urban100.
- [7] E. Agustsson y R. Timofte, "NTIRE 2017 Challenge on Single Image Super-Resolution: Dataset and Study," CVPR Workshops, 2017.